

LIBRIS

Sistema inteligente de búsqueda y recomendación de libros

Propuesta de mini-proyecto · SQL Server 2025 · DP-800

Propuesta técnica para validación del proyecto

1. Resumen de la propuesta

Libris será una biblioteca inteligente desarrollada principalmente sobre SQL Server 2025. El sistema combinará un catálogo relacional de libros con búsqueda de texto completo, embeddings y búsqueda vectorial para permitir consultas en lenguaje natural y recomendaciones personalizadas.

La idea principal no es construir una aplicación web completa, sino demostrar de forma reproducible capacidades de desarrollo SQL, seguridad, optimización e inteligencia artificial dentro del alcance de la práctica. **La interfaz gráfica se considera una ampliación opcional.**

Objetivo técnico

Conseguir un Nivel 3 mediante una solución RAG local, manteniendo como núcleo estable un Nivel 2 completo: diseño SQL, embeddings, tipo VECTOR, búsqueda semántica e Intelligent Search.

Entorno principal	SQL Server 2025 + SQL Server Management Studio
Nivel objetivo	Nivel 3, con Nivel 2 como núcleo funcional
IA local	Ollama mediante HTTPS local con Caddy
Interfaz	Opcional; la demostración principal podrá realizarse desde SSMS

2. Problema y caso de uso

Las búsquedas tradicionales de una biblioteca dependen normalmente de coincidencias por título, autor, género o palabras concretas. Libris pretende permitir búsquedas más naturales, por ejemplo:

“Quiero una novela de ciencia ficción sobre política y poder, con un tono serio y no demasiado larga.”


El sistema deberá recuperar libros relevantes aunque la sinopsis no contenga exactamente las mismas palabras. Además, podrá modificar el orden final de los resultados teniendo en cuenta el historial de préstamos y las valoraciones del socio.

3. Alcance funcional

- Gestión de libros, autores, géneros, socios, préstamos y valoraciones.
- Búsqueda tradicional mediante Full-Text Search con configuración lingüística en español.
- Generación y almacenamiento de embeddings en SQL Server 2025 mediante una columna VECTOR.
- Búsqueda semántica exacta mediante VECTOR_DISTANCE con métrica cosine.
- Búsqueda híbrida combinando Full-Text y ranking vectorial mediante Reciprocal Rank Fusion (RRF).

- Recomendaciones personalizadas utilizando préstamos y valoraciones como señales del perfil del usuario.
- Seguridad mediante roles/permisos, Row-Level Security y Dynamic Data Masking.
- Uso documentado de GitHub Copilot en SSMS como desarrollo SQL asistido por IA.
- RAG local: recuperación de libros relevantes, construcción del contexto y respuesta mediante un LLM ejecutado en Ollama.
- Interfaz gráfica o chat visual únicamente como mejora si el núcleo técnico está completado, más no se descarta usar python para mostrar la consola y datos básicos de la base de datos.

4. Arquitectura propuesta



Flujo de embeddings: SQL Server registra el modelo con CREATE EXTERNAL MODEL y solicita embeddings mediante AI_GENERATE_EMBEDDINGS. El endpoint HTTPS local será atendido por Caddy y redirigido a Ollama.

Flujo RAG: la pregunta recupera los libros más relevantes; SQL Server construye el contexto y realiza una llamada HTTPS al endpoint de chat de Ollama mediante sp_invoke_external_rest_endpoint.

5. Modelo de datos inicial

Tabla	Finalidad	Relaciones principales
Libros	Catálogo, sinopsis, ISBN, metadatos, texto preparado y embedding.	Calificaciones, Autores, Prestamos, Calificaciones
Autores	Datos de autores.	LibrosAutores
LibrosAutores	Relación N:M entre libros y autores.	Libros, Autores
Generos	Clasificación temática.	GenerosLibros
GenerosLibros	Relación N:M entre libros y géneros.	Libros, Generos

Tabla	Finalidad	Relaciones principales
Miembros	Socios y datos necesarios para seguridad/personalización.	Prestamos, Calificaciones
Prestamos	Historial de préstamos y estado.	Miembros, Libros
Calificaciones	Valoraciones de los socios.	Miembros, Libros
HistorialBusqueda	Registro opcional de búsquedas para análisis y pruebas.	Miembros

Embedding propuesto: texto compuesto por título, autor(es), género(s) y sinopsis. Modelo preferente: EmbeddingGemma, con vector de 768 dimensiones; all-minilm queda como alternativa de compatibilidad.

6. Búsqueda inteligente y personalización

6.1 Full-Text Search

Se creará un catálogo e índice Full-Text sobre campos relevantes del libro, principalmente título y sinopsis. La configuración lingüística será española para aprovechar los analizadores de texto del motor.

6.2 Búsqueda vectorial

La consulta del usuario se convertirá en embedding y se comparará con los embeddings almacenados mediante VECTOR_DISTANCE usando distancia cosine. Esta búsqueda exacta será la implementación base porque no depende de características preview.

6.3 Búsqueda híbrida con RRF

Los valores de distancia vectorial y el RANK de Full-Text no se sumarán directamente, ya que están en escalas diferentes. Cada lista se transformará en posiciones y se combinará mediante Reciprocal Rank Fusion (RRF), utilizando una expresión del tipo $1 / (k + \text{posición})$. De esta forma se fusionan rankings sin exigir una normalización común.

6.4 Personalización

El ranking híbrido se ajustará mediante señales derivadas del perfil de cada socio: géneros mejor valorados, libros con puntuaciones altas e historial de préstamos. Se utilizarán CTE y window functions para calcular afinidades y excluir o reducir el peso de libros ya leídos.

7. Correspondencia con los bloques de la práctica

Bloque	Implementación en Libris	Estado objetivo
A · Diseño y desarrollo	PK/FK/CHECK, índices, datos de prueba, views, stored procedures, function, trigger; CTE, window functions, JSON y regex.	Obligatorio

Bloque	Implementación en Libris	Estado objetivo
B · SQL asistido por IA	Uso de Copilot en SSMS documentado en docs/ai-assisted-log.md: prompt, respuesta, correcciones y validación.	Obligatorio
C · Seguridad	Roles y GRANT/DENY, RLS para préstamos propios y Dynamic Data Masking en email.	Obligatorio
D · Optimización	Execution Plan, logical reads y comparación antes/después en una consulta significativa. Índice vectorial aproximado como mejora adicional si se habilitan previews.	Planificado
E · Modelos y embeddings	CREATE EXTERNAL MODEL + AI_GENERATE_EMBEDDINGS con modelo local en Ollama; almacenamiento en VECTOR.	Obligatorio
F · Intelligent Search	Full-Text + VECTOR_DISTANCE + ranking híbrido RRF + personalización.	Obligatorio
G · RAG	Top-K → contexto → LLM local mediante Ollama → respuesta final.	Objetivo Nivel 3

8. T-SQL avanzado previsto

- CTE para preparar perfiles, candidatos y rankings intermedios.
- ROW_NUMBER, RANK y funciones de ventana para recomendaciones y RRF.
- JSON para construir/interpretar metadatos, contexto o respuestas de endpoints.
- REGEXP_LIKE para validar formatos como ISBN u otros campos de entrada.
- Fuzzy string matching para tolerar erratas en autores o títulos, si se habilitan las características preview.
- Stored procedures principales: búsqueda híbrida, recomendaciones y RAG.

9. Seguridad

- Rol de administración/bibliotecario con permisos de mantenimiento del catálogo.
- Rol de socio/lector con permisos limitados y ejecución de procedimientos autorizados.
- Row-Level Security para que cada socio consulte únicamente sus propios préstamos.
- Dynamic Data Masking sobre el correo electrónico para usuarios sin privilegios de desenmascarado.
- Principio de mínimo privilegio y pruebas con EXECUTE AS USER / REVERT.

10. Nivel 3: RAG

La fase RAG se construirá sobre el motor de búsqueda ya validado. No sustituye a la búsqueda; la reutiliza como mecanismo de recuperación.

1. Recibir una pregunta en lenguaje natural.
2. Generar el embedding de la pregunta.
3. Recuperar los libros más relevantes mediante la búsqueda híbrida.
4. Construir un contexto reducido y trazable con los resultados recuperados.
5. Enviar pregunta + contexto a un LLM local en Ollama a través del endpoint HTTPS expuesto por Caddy.
6. Devolver la respuesta final conservando evidencia de la pregunta, documentos recuperados, contexto y salida del modelo.

Diseño defensivo

El retrieval y la construcción de contexto se implementarán como pasos independientes. De este modo pueden demostrarse y probarse incluso antes de conectar la generación final del LLM.

11. Optimización y características preview

La solución base no dependerá de VECTOR_SEARCH. La búsqueda semántica exacta se realizará con VECTOR_DISTANCE. Si el entorno permite habilitar PREVIEW_FEATURES, se añadirá CREATE VECTOR INDEX / VECTOR_SEARCH como experimento de optimización y se comparará con la consulta exacta.

Para garantizar el Bloque D incluso si una característica preview presenta limitaciones, también se podrá analizar una consulta relacional significativa (por ejemplo, préstamos activos o recomendaciones por usuario) y estudiar el efecto de un índice convencional o compuesto mediante Execution Plan, logical reads y tiempos.

12. Fases de desarrollo

Fase	Objetivo
Fase 1 · Validación técnica	Comprobar SQL Server 2025, compatibilidad 170, Full-Text, Ollama, Caddy/HTTPS, CREATE EXTERNAL MODEL y una generación mínima de embeddings.
Fase 2 · Diseño y datos	Crear el modelo relacional, constraints, índices iniciales, datos de prueba y estructura del repositorio.
Fase 3 · Programación T-SQL	Implementar views, stored procedures, function, trigger y consultas avanzadas.
Fase 4 · Seguridad	Configurar roles/permisos, RLS y Dynamic Data Masking con pruebas por usuario.

Fase	Objetivo
Fase 5 · Embeddings y vector	Preparar el texto semántico de los libros, generar embeddings y validar VECTOR_DISTANCE con cosine.
Fase 6 · Intelligent Search	Crear Full-Text Search, fusionar rankings mediante RRF y añadir personalización por usuario.
Fase 7 · RAG	Construir el contexto de recuperación e integrar un LLM local mediante Ollama.
Fase 8 · Optimización y pruebas	Medir consultas, aplicar mejoras, crear tests reproducibles y guardar evidencias de ejecución.
Fase 9 · Documentación y entrega	README, arquitectura, informe PDF, presentación, capturas y revisión final de reproducibilidad.

13. Viabilidad técnica del entorno

La arquitectura se ha planteado para ejecutarse en local sobre Windows 11. Antes de construir el resto del proyecto se validarán los siguientes puntos:

- SQL Server 2025 (17.x) operativo y base de datos con compatibility level 170. ✓
- Componente Full-Text instalado en la instancia y lenguaje español disponible. ✓
- Ollama operativo en localhost con el modelo de embeddings descargado. ✓
- Caddy operativo como reverse proxy HTTPS local y certificado raíz confiado por Windows. ✓
- CREATE_EXTERNAL_MODEL apuntando al endpoint HTTPS /api/embed.
- AI_GENERATE_EMBEDDINGS devuelve un vector con la dimensión esperada.
- sp_invoke_external_rest_endpoint habilitable para la fase de RAG.
- PREVIEW_FEATURES sólo se activará cuando sea necesario para fuzzy matching o índice vectorial aproximado.

```

PowerShell 7.6.6
PS C:\Users\AlumnoM_AI> certutil -addstore -f Root "$env:APPDATA\Caddy\pki\authorities\local\root.crt"
Root "Entidades de certificación raíz de confianza"
La firma coincide con la clave pública
El certificado "Caddy Local Authority - 2026 ECC Root" se ha agregado al almacén.
CertUtil: -addstore comando completado correctamente.
PS C:\Users\AlumnoM_AI> Invoke-WebRequest -Uri https://localhost:11435/api/embed `
>> -Method Post -ContentType 'application/json'
>> -Body '{"model":"all-minilm","input":"hola"}'

model      : all-minilm
embeddings : {-0,065268025 0,092715956 -0,026071953 -0,01608363 -0,06027008 -0,094768494 0,1342484 -0,065623336
              -0,0418367 -0,015467647 0,018980252 0,016654974 -0,07684611 -0,016441373 0,05058897 -0,012224599
              -0,038301684 -0,06844666 -0,14003348 -0,014562622 -0,009812123 0,079116605 -0,06462245 0,042419374
              -0,00077012024 0,035089497 0,038571596 0,048055883 0,022540448 -0,012693757 0,0027341484
              0,058760814 0,020483984 -0,016273031 -0,030458797 -0,035098203 -0,09653793 -0,06298967 0,028150462
              0,0073824315 0,009612377 -0,033263654 -0,034251094 0,016698357 0,039941985 -0,060566824
              -0,018404722 -0,037328463 0,044442404 0,027701618 -0,07245934 0,0063391468 0,034961972 -0,016525378
              -0,012036181 0,06002219 0,039139304 -0,07114189 0,06660473 0,019489376 -0,0016308671 0,0032029112
              -0,12621395 0,11610954 -0,013190478 -0,049132932 0,015081334 -0,09016467 -0,07751999 0,065503016
              6,354465E-05 0,007689853 -0,00860617 0,00038100075 0,008409151 0,01247322 0,021291312 0,019952174
              0,06760178 0,049799684 0,031533096 0,045435824 -0,06286994 0,027062537 0,013025609 -0,013651242
              -0,028178545 -0,03845656 0,007561533 -0,025044242 -0,11749897 -0,019644853 0,06291436 -0,013470499
              0,018506436 -0,0060851844 -0,0013257304 -0,009219061 -0,04641402 0,16918153 0,043074753
              0,022099307 0,07901057 0,086960495 -0,004508691 -0,0010012757 -0,005348512 0,0850872 -0,0110126445
              0,029656801 -0,06779115 -0,013182079 0,013104311 0,007093988 -0,03291457 0,08852466 -6,5258566E-05
              0,05398463 0,07078227 -0,09795294 0,060003158 -0,033850666 0,022844784 -0,019494727 0,04356316
              -0,107538335 -0,029546566 -1,7182245E-33 0,056988154 -0,055257514 0,056603134 0,061034497
              0,027635375 -0,019147368 -0,008972883 -0,019089088 -0,020519983 -0,0021274118 -0,03762258
              0,0530044 -0,045422427 -0,017280422 -0,018509666 0,048486825 0,025269812 0,073612764 0,046126008

```

Programa de instalación de SQL Server 2025

Selección de características

Seleccione las características de Desarrollador estándar que desea instalar.

Reglas globales

Actualizaciones de productos

Instalar archivos de configuraci...

Instalar reglas

Tipo de instalación

Extensión de Azure para SQL Se...

Selección de características

Reglas de características

Configuración del servidor

Reglas de configuración de car...

Listo para instalar

Progreso de la instalación

Operación completada

¿Está buscando Power BI Report Server? [Descargar de la Web](#)

Características:

Características de instancia

☒ Servicios de Motor de base de datos

☐ Replicación de SQL Server
 ☒ Extensiones de lenguaje y servicios de IA
 ☒ Extracciones de texto completo y semánticas de búsqueda
 ☐ Servicio de consultas de PolyBase para datos externos
 ☐ Analysis Services

Características compartidas

☐ Integration Services
 ☐ Servicio de trabajo de Escalabilidad horizontal

Características redistribuibles

Seleccionar todo

Anular la selección de todo

Directorio raíz de instancia:

C:\Program Files\Microsoft SQL Server\

Directorio de características compartidas:

C:\Program Files\Microsoft SQL Server\

Directorio de características compartidas (x86):

C:\Program Files (x86)\Microsoft SQL Server\

Descripción de la característica:

La configuración y operación de cada característica de una instancia de SQL Server tiene lugar de forma aislada con respecto a otras instancias de SQL Server. Las instancias de SQL Server pueden operar en paralelo en el mismo equipo.

Requisitos previos de las características seleccionadas:

Ya instalado:

Microsoft Visual C++ 2017 Redistributable

Microsoft MPI v10

Requisitos de espacio en disco

Unidad: C 846 MB requeridos, 688162 MB disponibles

< Atrás

Siguiente >

Cancelar

14. Tecnologías previstas

Tecnología	Uso
SQL Server 2025	Motor de base de datos, T-SQL, seguridad, Full-Text, VECTOR y funciones de IA.
SQL Server Management Studio	Desarrollo, pruebas y demostración principal.
Git + GitHub	Control de versiones, código y documentación reproducible.
GitHub Copilot en SSMS	Asistencia de desarrollo SQL documentada y validada.
Ollama	Ejecución local de modelos de embeddings y del LLM para RAG.
Caddy	Reverse proxy HTTPS local entre SQL Server y Ollama.
EmbeddingGemma	Modelo preferente de embeddings multilingüe; VECTOR(768).
LLM local ligero	Generación de respuesta RAG; modelo final elegido según recursos del equipo.

15. Estructura prevista del repositorio

```
libris/
├── README.md
├── database/
│   ├── 01_database.sql
│   ├── 02_tables.sql
│   ├── 03_seed.sql
│   ├── 04_views_functions.sql
│   ├── 05_procedures.sql
│   ├── 06_security.sql
│   └── 07_indexes_optimization.sql
├── ai/
│   ├── 01_external_model.sql
│   ├── 02_embeddings.sql
│   ├── 03_vector_search.sql
│   ├── 04_hybrid_search.sql
│   └── 05_rag.sql
├── tests/
│   └── tests.sql
├── docs/
│   ├── arquitectura.png
│   └── ai-assisted-log.md
```

16. Criterios de éxito

- La base de datos puede crearse desde cero ejecutando los scripts del repositorio.
- Un usuario puede realizar una búsqueda en lenguaje natural y obtener un ranking reproducible de libros relevantes.
- La solución demuestra de forma diferenciada Full-Text, búsqueda vectorial y búsqueda híbrida.
- Las recomendaciones cambian de forma justificable según el perfil del socio.
- Los mecanismos de seguridad se demuestran con usuarios/permisos distintos.
- El uso de IA asistida durante el desarrollo queda documentado y validado.
- El RAG, si se completa, permite identificar claramente pregunta, documentos recuperados, contexto y respuesta final.
- Cada funcionalidad importante dispone de evidencia de ejecución y explicación.

17. Entregables

- Repositorio GitHub con todos los scripts y archivos necesarios para reproducir la solución.
- README principal con instalación, arquitectura y funcionalidades implementadas.
- Informe técnico en PDF.
- Presentación breve para exposición y demostración.
- Scripts SQL y pruebas de ejecución.

18. Referencias técnicas de la propuesta

[Microsoft Learn · CREATE EXTERNAL MODEL \(SQL Server 2025\)](#)

[Microsoft Learn · VECTOR_SEARCH](#)

[Microsoft Learn · CREATE VECTOR INDEX](#)

[Microsoft Learn · Full-Text Search](#)

[Microsoft Learn · sp_invoke_external_rest_endpoint](#)

[Microsoft Learn · SQL Server 2025 release notes](#)

[Ollama · EmbeddingGemma](#)

[Caddy · Automatic HTTPS](#)

Propuesta final

Libris prioriza una solución pequeña, reproducible y técnicamente demostrable. El Nivel 2 constituye el núcleo estable de la entrega y el Nivel 3 se construye sobre ese mismo flujo mediante RAG local, sin hacer depender la práctica de una interfaz gráfica.